

HideAndSeek_Transformer プロジェクト引き継ぎ資料

1. プロジェクト概要と進捗

MuJoCo物理エンジンを用いた「2 Hiders vs 1 Seeker(かくれんぼ)」のマルチエージェント強化学習環境において、PPO + Transformerを用いたエージェントを育成・共進化させるプロジェクト。

演習の変遷

- 第14-16回 (main15.py): LSTM版PPOの実装。環境構築(壁、スロープ、箱、ロック機能)と共進化基盤の確立。
- 第17回: 記憶メカニズムをLSTMからTransformer (Encoder-only) へ刷新。
- 第18回 (main18_optimization.py):
 - 最適化: 計算コスト増大に対処するため、ゼロコピーバッファ、視界判定キャッシュ、環境依存並列化を実装しSPSを改善。
 - 感度分析: 環境ごとの最適パラメータを特定。
 - 安定化: 継続学習(チェックポイント)機能の実装、ログ出力の適正化。
- 第19回 (main19_reward_optimization.py):
 - 報酬最適化: Optunaを用いて、エピソード長(生存時間)を最大化する報酬パラメータを自動探索するスクリプトの実装。

2. 現在の技術スタックと動作環境

- 言語/FW: Python 3.x, PyTorch, Gymnasium, Stable-Baselines3 (参考), MuJoCo
- 環境依存制御:
 - Windows (Intel/AMD): 環境変数 OMP_NUM_THREADS=1 等を設定し、CPU競合を回避。
 - Mac (Apple Silicon): 環境変数の制限を行わない方が高速であるため、制限をスキップ。

3. 決定事項と設計思想

1. 軽量Transformer: 感度分析に基づき HIDDEN_DIM=64, LAYERS=2, HEADS=2, SEQ_LEN=8 を採用(※v18.52以降の設定)。
2. ObsHistoryのゼロコピー化: リングバッファのダブルバッファリングにより torch.cat を排除し高速化。
3. 視界判定のキャッシュ: 重いRayCastをFOV判定と分離し、微小移動(<5cm)時は前回の結果を再利用。
4. エピソード境界: done=True 時にバッファをゼロクリアせず、文脈を維持したまま上書きする。
5. 公平な比較: パラメータ探索時は LOAD_EXISTING_MODELS=False, FIXED_SEED=1 とする。

4. 【重要】過去のトラブルと解決策(Lessons Learned)

※再発防止のため厳守

- **WandB**ログ切れ: エピソードごとの生データ記録はデータ数が膨大になるため廃止。「更新(**Update**)ごとの平均値」のみを記録する。
- 継続学習の**SPS**異常: `global_step` を引き継ぐ際、経過時間で単純に割るとSPSが異常値になる。 $(current_step - start_step) / elapsed_time$ で計算する。
- **Viewer**モードのクラッシュ: `USE_VIEWER=True` 時は環境数が強制的に1になる。コード内の `NUM_ENVS` 定数ではなく、動的に設定される `actual_num_envs` を使用する。
- **Transformer**の警告: 固定長シーケンスの場合 `enable_nested_tensor=True` は不要かつ警告が出るため、明示的に `False` にする。
- パラメータ置換のバグ (**main19**): `re.sub` で数値を置換する際は `r"\1"` ではなく `r"\g<1>"` を使用する(直後の数値との結合回避)。
- モデル破壊 (**main19**): `refinement` モードでモデル名を変えない場合、終了時に上書きされてしまう。スクリプト内で `torch.save` をコメントアウトする処理を入れる。

5. 次のアクション

1. 学習曲線のMAEが平坦になり学習が進まない問題点の原因を追求する。
2. `main19_reward_optimization.py` を実行し、最適な報酬設定を探索・特定する。
3. 特定した設定を `main18_optimization.py` に反映し、300万ステップ以上の長時間学習を行う。